Taller 1 Sistemas Avanzados de producción

Presenta:

Autor 1 Santiago Niño Medina 123772
Autor 2 Estevan Camilo Ortiz Caita 123253
Autor 3 Marlon Leandro Salamanca 123213

Asignatura:
Sistemas avanzados de Producción

Docente:
Fredy Alexander Orjuela López

Universidad Ecci
01/ 03 / 2025
Bogotá D.C

Introducción

En el contexto empresarial, comprender el impacto de la inversión publicitaria sobre las ventas es fundamental para una adecuada toma de decisiones estratégicas. Las organizaciones buscan determinar qué tan efectiva es la asignación de recursos en distintos canales de comunicación y cómo estos influyen en el desempeño comercial.

El presente análisis tiene como objetivo evaluar la relación existente entre la inversión en publicidad (TV, radio y prensa) y el nivel de ventas, cuantificar la magnitud de dicha asociación mediante herramientas estadísticas como la correlación y la regresión lineal, y analizar la capacidad explicativa y predictiva de los modelos estimados. A través de este estudio, se pretende determinar qué variables contribuyen de manera significativa al comportamiento de las ventas y qué tan adecuado es el modelo propuesto para describir la realidad observada.

Fase 1: Estadística Descriptiva y Análisis Exploratorio

1. **Caracterización Numérica**

Variable	Media	Mediana	Desv. Estándar	Mínimo	Máximo	Asimetría	Curtosis
TV	147.0425	149.75	85.854236	0.7	296.4	-0.069853	-1.226495
Radio	23.2640	22.90	14.846809	0.0	49.6	0.094175	-1.260401
Newspaper	30.5540	25.75	21.778621	0.3	114.0	0.894720	0.649502
Sales	14.0225	12.90	5.217457	1.6	27.0	0.407571	-0.408869

Tabla [1] Esta tabla muestra las medidas de tendencia central y dispersión para las variables independientes Y la variable Sales dependía.

2. Análisis de Distribución y Atípicos

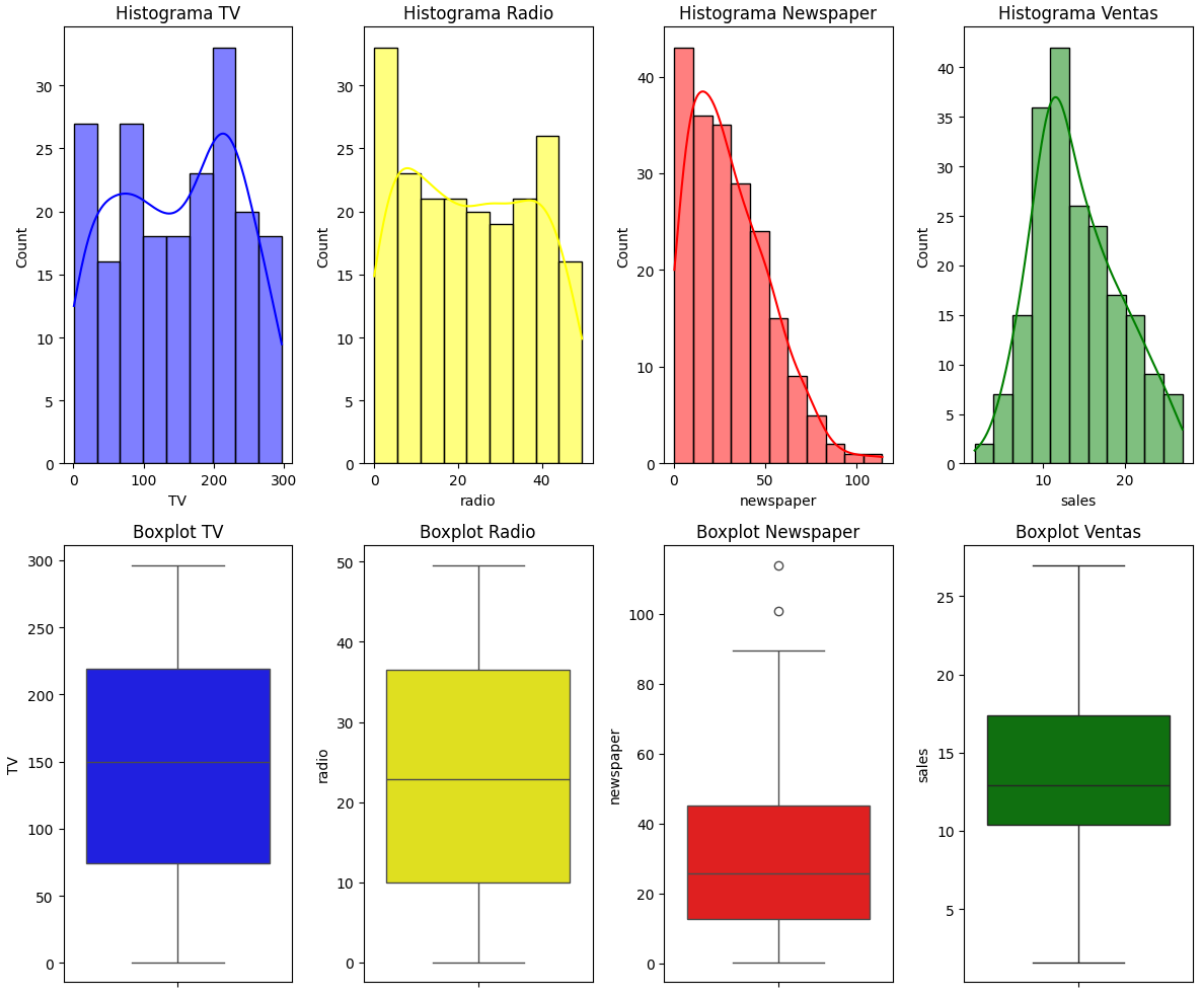

Gráfico [2] En este grafico se pueden analizar las distribuciones de cada una de las variables en las cuales se pueden observar los comportamientos de TV, Radio, Newspaper y Ventas. Para la interpretación de cada una de ellas se nombrará su respectiva distribución: TV (Azul) relativamente uniforme, Radio (Amarillo) distribución uniforme, Newspaper (Roja) distribución asimétrica positiva y Ventas (Verde) Normal (Gaussiana).

A. Simetría de las distribuciones: A partir del análisis de los histogramas y los diagramas de caja (Box Plots), se concluye lo siguiente respecto a la forma de los datos:

- **TV y Radio:** Presentan una distribución relativamente uniforme. No existe un sesgo marcado hacia la izquierda o derecha, sino que las inversiones publicitarias están repartidas de forma equilibrada en los distintos rangos.
- **Ventas (Sales):** Presenta una distribución más cercana a la Normal (Gaussiana). Los datos se concentran en el centro y se distribuyen de forma simétrica hacia los extremos.

- **Newspaper (Periódico):** Presenta una fuerte **asimetría positiva (sesgada a la derecha)**. La gran mayoría de los mercados tienen inversiones muy bajas en este medio, y solo unos pocos registran inversiones altas, lo que genera una "cola" larga hacia el lado derecho del histograma.

B. Identificación de datos atípicos (Outliers): Para las variables de TV, Radio y Ventas, hay una ausencia de valores atípicos, ya que no se observan puntos aislados por encima o por debajo de los "bigotes" en sus diagramas de caja. Sin embargo, **sí se identifican datos atípicos en la variable Newspaper**. En su Box Plot, se observan claramente dos puntos individuales que superan el límite superior del bigote, representando mercados con inversiones en periódicos excepcionalmente altas que se alejan de la masa general de los datos.

C. Influencia de estas observaciones en una línea de regresión: La presencia de estos datos atípicos en la variable *Newspaper* es crítica porque el modelo de regresión lineal es muy sensible a los outliers. Dado que el modelo busca minimizar los errores al cuadrado (Mínimos Cuadrados Ordinarios), estos valores extremos pueden "tirar" de la línea de ajuste hacia ellos.

Como resultado, la recta de regresión se desvía de la tendencia general de la mayoría de los datos, aumentando el error cuadrático medio. A nivel de negocio, esto significa que los coeficientes del modelo podrían distorsionarse, llevándonos a conclusiones erróneas sobre el verdadero impacto que tiene invertir en periódicos sobre el volumen final de ventas.

3. **Exploración de la nube de puntos**
   Genere los dispersogramas (Scatter Plots) de la variable respuesta (Sales) frente a cada covariable. Identifique visualmente si la nube de puntos sugiere una relación lineal simple o si existen patrones más complejos (parábolas, segmentos o datos influyentes).
4. **Evaluación de asociación: Pearson y Sperman**

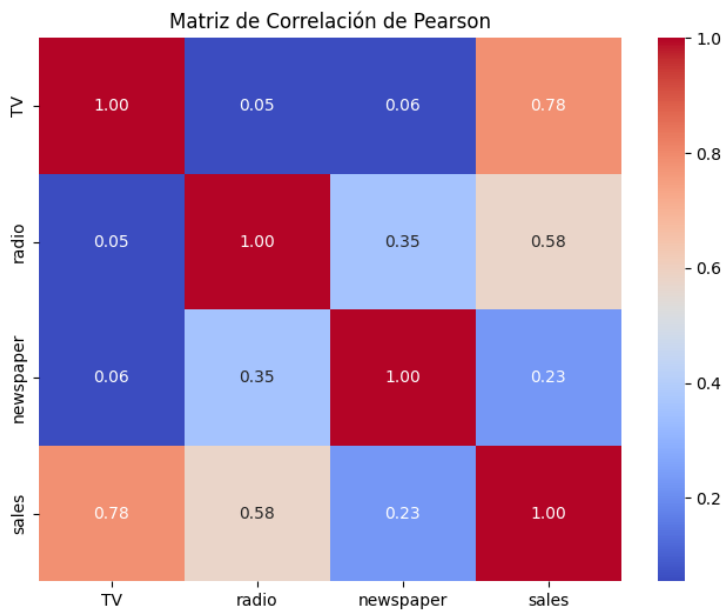

Grafico [3] Este coeficiente evalúa la fuerza de la asociación lineal. Los resultados indican que la inversión en TV es el predictor lineal más fuerte de las ventas (~0.78), seguido por un impacto moderado de la Radio (~0.58) y uno muy débil del Periódico (~0.23). Asimismo, la correlación casi nula entre los propios canales (ej. TV y Radio) confirma la ausencia de multicolinealidad.

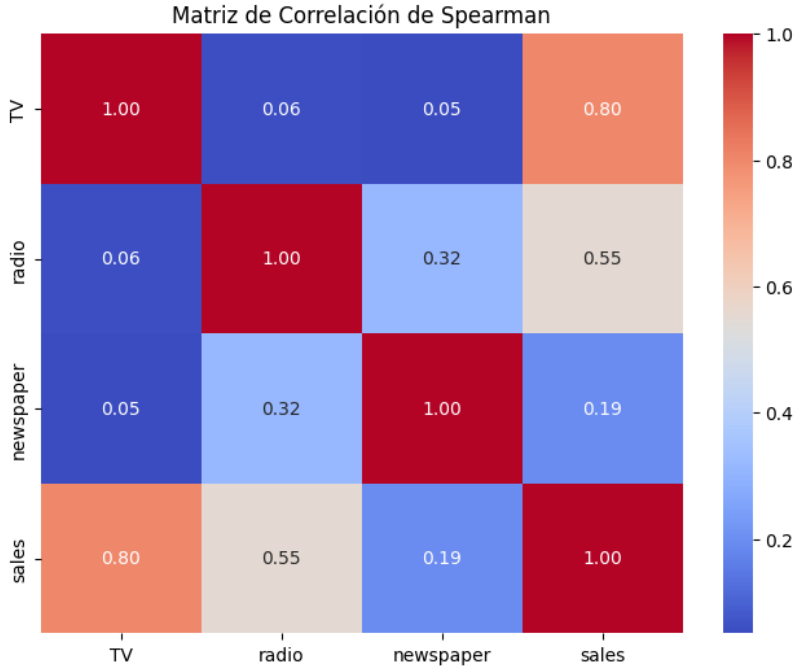

Gráfico [4] Este coeficiente identifica relaciones monótonas basadas en rangos. Se observa que el valor para TV-Ventas (~0.80) es ligeramente superior al de Pearson, lo que sugiere que la asociación comercial no es estrictamente lineal; es decir, las ventas crecen con la inversión en TV, pero apuntan a un efecto de rendimientos marginales decrecientes.

5. **Interpretación de Resultados:**

   ¿Qué significa un coeficiente cercano a 1 o −1 en el contexto de la inversión publicitaria y el retorno en ventas?

   Un coeficiente de correlación cercano a 1 indica una relación positiva fuerte entre la inversión publicitaria y las ventas. Es decir, cuando aumenta la inversión, las ventas también aumentan de manera consistente.

   Un coeficiente cercano a −1 indicaría una relación negativa fuerte, lo que significaría que, al aumentar la inversión, las ventas disminuyen (lo cual en este contexto sería poco lógico).

   En la matriz observada, por ejemplo, la correlación entre TV y sales (0.78) indica una relación positiva fuerte, lo que sugiere que invertir en televisión está fuertemente asociado con mayores ventas.

   ¿Como se interpreta un valor de correlación cercano a 0?

Un coeficiente cercano a 0 indica que no existe una relación lineal significativa entre las variables.

Por ejemplo:

- TV y radio (0.05)
- TV y newspaper (0.06)

Estos valores muestran que prácticamente no hay relación lineal entre esas variables.

- Pearson mide relación lineal.
- Spearman mide relación monótona (no necesariamente lineal, sino que mantenga una tendencia creciente o decreciente).

Si ambos coeficientes (Pearson y Spearman) son similares y relativamente altos, esto sugiere que la relación es no solo monótona sino también aproximadamente lineal.

En este caso, dado que la nube de puntos (especialmente TV vs sales) muestra una tendencia creciente bastante alineada y los coeficientes son altos, se puede concluir que la relación es principalmente lineal.

Si hubiera una relación curva (por ejemplo, exponencial), Spearman sería alto pero Pearson sería más bajo.

Fase 2: Regresión Lineal y Diagnóstico

1. **Modelamiento Múltiple:**

   - **Intercepto (beta_0): 2.9389**
   - **Intercepto (beta_1): 0.0458**
   - **Intercepto (beta_2): 0.1885**
   - **Pendiente (beta_3): -0.0010**

2. **Interpretación de Parámetros:**
   Explique con sus propias palabras el significado de los resultados obtenidos:
   Interprete el intercepto ˆβ0 indicando si tiene sentido conceptual que sea diferente de cero.
   Interprete los coeficientes ˆβ1, ˆβ2 y ˆβ3 bajo el concepto de variación de la media de Y cuando hay un incremento unitario de la covariable, manteniendo la otra constante (*ceteris paribus*) **(minuto 22)**

Intercepto (β_0 = 2.9389)

El intercepto nos dice cuánto se vendería si no se invirtiera nada en publicidad, es decir, si TV, radio y periódico fueran cero.

En este caso, el modelo dice que aun sin invertir en nada, se venderían aproximadamente 2.94 unidades.

Coeficiente de TV (β_1 = 0.0458)

Este número significa que, si aumentamos en 1 unidad la inversión en TV, y dejamos igual la inversión en radio y periódico, las ventas aumentarían en promedio 0.0458 unidades.

Si gastas un poquito más en televisión, las ventas suben un poquito también.

Coeficiente de Radio (β_2 = 0.1885)

Este valor dice que, si aumentamos en 1 unidad la inversión en radio, manteniendo lo demás igual, las ventas aumentan en promedio 0.1885 unidades.
La radio parece tener un impacto más fuerte que la TV, porque por cada peso adicional invertido, el aumento en ventas es mayor.

Coeficiente de Newspaper (β_3 = −0.0010)

Este valor es negativo y muy pequeño.

Significa que, si aumentamos en 1 unidad la inversión en periódico, dejando lo demás igual, las ventas bajan en promedio 0.0010 unidades.

Pero es tan pequeño que prácticamente no cambia nada.

3. Análisis de Bondad de Ajuste

TV

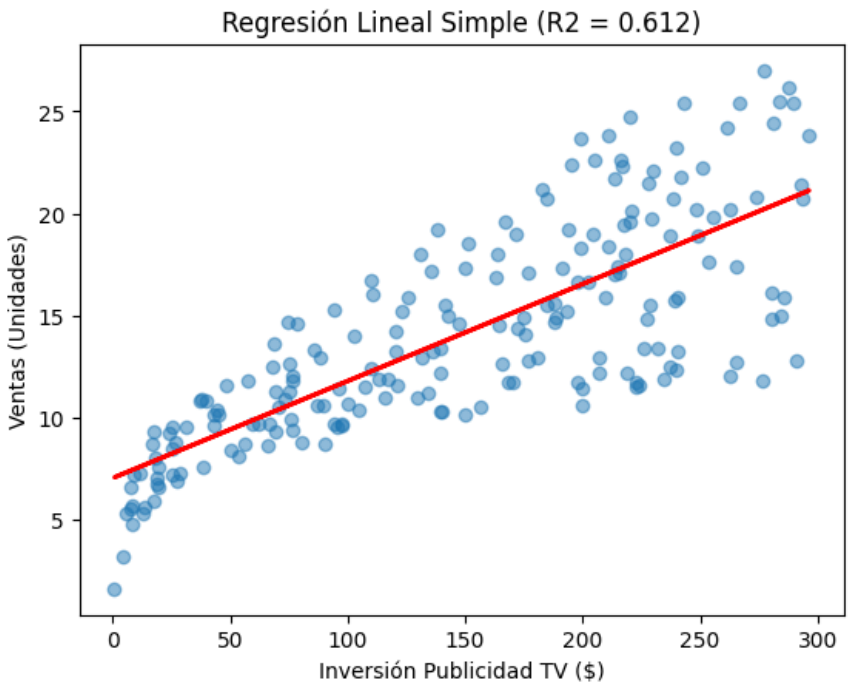

Grafica [5] Esta regresión lineal representa Distribución amplia y sin una tendencia central fuerte. No presenta datos atípicos.

Radio

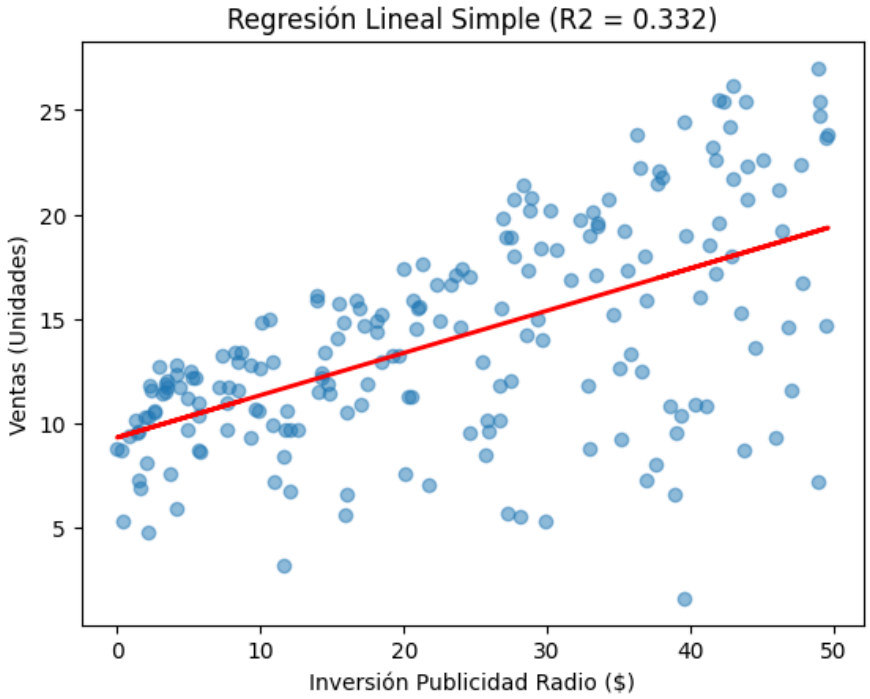

Grafica [6] Esta regresión lineal representa Distribución uniforme (plana) y simétrica. Sin presencia de datos atípicos.

Newspaper

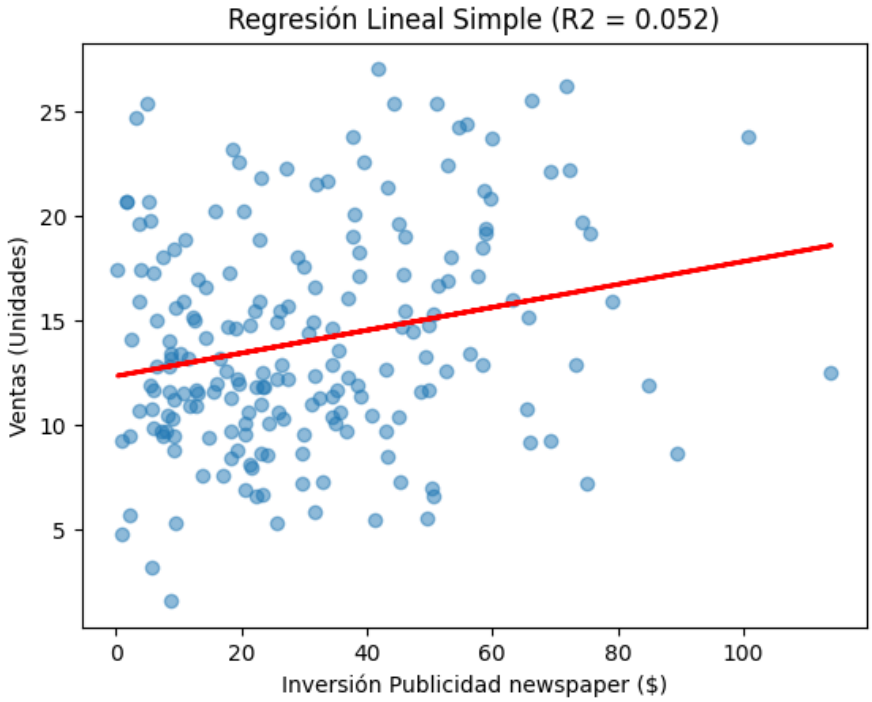

Grafica [7] Esta regresión lineal representa Fuerte asimetría positiva (sesgada a la derecha) con dos datos atípicos superiores evidentes.

R-cuadrado (R2): 0.8972

El modelo múltiple presenta un coeficiente de determinación de aproximadamente 0.897, lo que indica que el 89.7% de la variabilidad de las ventas es explicada por la inversión en TV, Radio y Newspaper. Comparado con el modelo simple de la Fase 1 ($R^2 \approx 0.61$), la inclusión de Radio y Newspaper mejora significativamente el ajuste. No obstante, el impacto de Newspaper es prácticamente nulo, por lo que la mejora del modelo se debe principalmente a la variable Radio.

4. **Estimación Matricial:**

Formulacion Matricial

$$X = \begin{pmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \\ 1 & 4 \\ 1 & 5 \end{pmatrix}, \quad y = \begin{pmatrix} 2 \\ 4 \\ 6 \\ 7 \\ 9 \end{pmatrix}$$

Transpuesta

$$X' = \begin{pmatrix} 1 & 1 & 1 & 1 & 1 \\ 1 & 2 & 3 & 4 & 5 \end{pmatrix}$$

Producto $X'X$

$$X'X = \begin{pmatrix} 1 & 1 & 1 & 1 & 1 \\ 1 & 2 & 3 & 4 & 5 \end{pmatrix} \begin{pmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \\ 1 & 4 \\ 1 & 5 \end{pmatrix}$$

$$X'X = \begin{pmatrix} 5 & 15 \\ 15 & 55 \end{pmatrix}$$

Inversa $(X'X)^{-1}$

$$A^{-1} = \frac{1}{ad - bc}\begin{pmatrix} d & -b \\ -c & a \end{pmatrix}$$

$$(5)(55) - (15)(15) = 275 - 225 = 50$$

$$(X'X)^{-1} = \frac{1}{50}\begin{pmatrix} 55 & -15 \\ -15 & 5 \end{pmatrix} = \begin{pmatrix} 1.1 & -0.3 \\ -0.3 & 0.1 \end{pmatrix}$$

Producto $X'y$

$$y = \begin{pmatrix} 2 \\ 4 \\ 6 \\ 7 \\ 9 \end{pmatrix} \qquad \begin{aligned} \Sigma y &= 28 \\ \Sigma xy &= 100 \end{aligned}$$

$$X'y = \begin{pmatrix} 28 \\ 101 \end{pmatrix}$$

Parametro $\hat{\beta}$

$$\hat{\beta} = \begin{pmatrix} 1.1 & -0.3 \\ -0.3 & 0.1 \end{pmatrix}\begin{pmatrix} 28 \\ 101 \end{pmatrix}$$

Intercepto

$$\begin{aligned} \hat{\beta}_0 &= (1.1)(28) + (-0.3)(101) \\ &= 30.8 - 30.3 \\ &= 0.5 \end{aligned}$$

pendiente

$$\begin{aligned} \hat{\beta}_1 &= (-0.3)(28) + (0.1)(101) \\ &= -8.4 + 10.1 \\ &= 1.7 \end{aligned}$$

Ecuacion Final

$$\hat{y} = 0.5 + 1.7x$$

Fase 3: Árboles de decisión y comparación de modelos

1. Entrenamiento del modelo

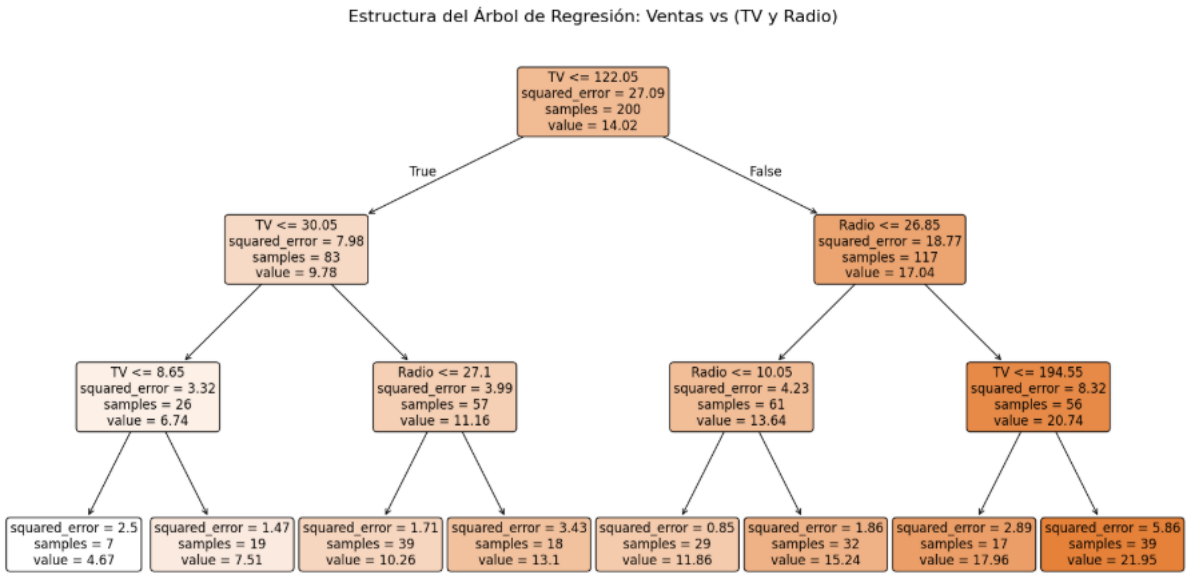

En este árbol de regresión, la partición de nodos se hace para minimizar el error cuadrático medio (MSE). En cada nodo, el algoritmo prueba muchos cortes posibles con TV o Radio y elige el que más reduce el MSE total entre las ramas izquierda y derecha.

En el gráfico lo ves así:

- squared_error: la variabilidad (MSE) dentro del nodo. Cuanto más baja, más "puro" es el grupo.
- samples: cuántos datos caen en ese nodo.
- value: el promedio de ventas que el nodo predice.

En resumen: se divide donde el grupo resultante queda más homogéneo en ventas (menor MSE).

2. Cálculo manual de incertidumbre (Clasificación):

Cálculo manual (paso a paso)

1) Conteos del nodo padre
Total: 4 mercados
Altas: 3
Bajas: 1

Probabilidades:

p(Altas) = 3/4
p(Bajas) = 1/4

2) Entropía del nodo padre

Fórmula:
$H(S) = - \Sigma p_i \log_2(p_i)$

Cálculo:
$H(S) = - [(3/4) \log_2(3/4) + (1/4) \log_2(1/4)]$
H(S) = 0.8113

3) Índice de Gini del nodo padre

G = 1 - Σ pi^2

G = 1 - (3/4)^2 - (1/4)^2 = 1 - 9/16 - 1/16 = 6/16 = 0.3750

4) Entropía tras dividir por inversión TV Grupo TV = Alta: 2 Altas, 0 Bajas H = 0

Grupo TV = Baja: 1 Altas, 1 Bajas H = 1

Entropía ponderada: H_split = (2/4) * 0 + (2/4) * 1 = 0.5

5) Ganancia de Información IG(S, TV) = H(S) - H_split = 0.8113 - 0.5 = 0.3113

Resultado final:

H(S) = 0.8113

G = 0.3750

H_split = 0.5

IG = 0.3113

3. Importancia de Predictores:

Mayor peso en el árbol de decisión: TV (importancia ≈ 0.6425) vs. Radio (≈ 0.3575).

Regresión múltiple, fase 2:

Coeficiente TV: 0.0458

Coeficiente radio: 0.1885

Coeficiente Newspaper: −0.0010

Comparación:

El árbol asigna más peso a TV.

La regresión múltiple muestra un coeficiente mayor para Radio, por lo que en el modelo lineal Radio tiene un impacto marginal más alto que TV.

4. Diagnóstico comparativo:

¿Cuándo conviene la regresión lineal?

Interpretabilidad alta: Cada coeficiente indica cuánto cambian las ventas por unidad invertida, manteniendo constantes las demás variables.

Relaciones aproximadamente lineales: si la nube de puntos muestra tendencia recta, la regresión es adecuada.

Estabilidad y generalización: Suele tener menor varianza y menos riesgo de sobreajuste.

Pocos datos: funciona bien con muestras pequeñas.

Objetivo explicativo: Ideal para reportes financieros y decisiones estratégicas basadas en “impacto marginal”.

¿Cuándo conviene un árbol de decisión?

No linealidades o umbrales: cuando el efecto cambia por rangos (ej. “a partir de TV > 120 suben más las ventas”).

Interacciones complejas: Captura combinaciones de variables sin definirlas manualmente.

Reglas claras tipo “si entonces”: útil para segmentar mercados y comunicar reglas operativas.

Mejor ajuste si el patrón es irregular: puede ganar precisión si la relación no es lineal.

Resumen comparativo

Interpretabilidad:

Regresión lineal: muy alta (coeficientes directos).

Árbol: alta, pero en forma de reglas segmentadas.

Precisión del pronóstico:

Regresión: mejor si la relación es lineal y estable.

Árbol: mejor si hay umbrales y no linealidad, pero con mayor riesgo de sobreajuste.

Conclusión práctica

Si se necesitas explicar impactos monetarios y tomar decisiones financieras es mejor regresión lineal.

Si necesitas segmentar y encontrar reglas basadas en rangos es mejor árbol de decisión.